

Demonstração analítica e numérica de propriedades dos grafos de Erdos Renyi e Watts Strogatz

Regina Duarte

Mestrado em Engenharia e Ciência de Dados
Instituto Superior Técnico
96986

Pedro Rio

Mestrado em Engenharia e Ciência de Dados
Instituto Superior Técnico
97241

Abstract

Neste projeto analisamos algumas propriedades de dois tipos de grafos estudados em aula - o modelo de Erdos Renyi e o modelo de Watts Strogatz. Em ambos os casos analisamos analiticamente e numericamente[4] a distribuição do grau, o coeficiente de agrupamento e o percurso médio dos grafos, tal como cada grafo se compara com grafos reais.

I. GRAFO ERDOS RENYI

O grafo Erdos Renyi é um grafo aleatório com dois parâmetros, n_{nodos} e $p_{\text{ligação}}$, onde n_{nodos} é o número de nodos do grafo e $p_{\text{ligação}}$ é a probabilidade de um nodo n_i estar ligado ao nodo n_j para todo o i e j . Aqui vamos considerar sempre que n_{nodos} é suficientemente grande e que o grau médio de cada nodo é $\langle k \rangle = np$. [3]

A. Distribuição do grau de um nodo

Nesta secção vamos mostrar que no modelo Erdos Renyi, a distribuição de probabilidades do grau de cada nodo segue uma distribuição binomial de parâmetros $n_{\text{nodos}} - 1$ e $p_{\text{ligação}}$ e que quando n_{nodos} toma valores muito grandes a distribuição pode ser aproximada ao modelo poisson com parâmetro $(n_{\text{nodos}} - 1)p_{\text{ligação}}$.

Sabemos que a probabilidade de um nodo i se ligar a outro é dada por $p_{\text{ligação}}$. Assim cada nodo pode ligar-se aos outros $n_{\text{nodos}} - 1$ com probabilidade $p_{\text{ligação}}$. Ou seja trata-se de uma sucessão de acontecimentos onde o nodo i se liga a outro nodo com probabilidade $p_{\text{ligação}}$ ou não se liga com probabilidade $1 - p_{\text{ligação}}$. Assim a probabilidade de um nodo i ter grau k , i.e. ligar-se a k nodos é dada por:

$$\binom{n_{\text{nodos}} - 1}{k} p_{\text{ligação}}^k (1 - p_{\text{ligação}})^{n_{\text{nodos}} - 1 - k}$$

onde $p_{\text{ligação}}^k$ representa a probabilidade do nodo se ligar a k nodos, multiplicado pela probabilidade do nodo i não se ligar aos outros $n_{\text{nodos}} - 1 - k$ nodos e ainda multiplicado por todas as combinações possíveis dos nodos que se ligam ao nodo i , $\binom{n_{\text{nodos}} - 1}{k}$. Ou seja, chegamos à conclusão que a distribuição do grau do grafo Erdos Renyi é binomial com parâmetros $n_{\text{nodos}} - 1$ e $p_{\text{ligação}}$.

Na figura 1 simulámos 100 grafos de Erdos Renyi com $n_{\text{nodos}} = 100$ e $p_{\text{ligação}} = 40\%$ e confirmámos numericamente que a média da distribuição do grau de um nodo segue uma distribuição binomial com parâmetros $n_{\text{nodos}} - 1$ e $p_{\text{ligação}}$.

Sendo $\langle k \rangle$ o grau médio do grafo, sabemos que:

$$\langle k \rangle = (n_{\text{nodos}} - 1)p_{\text{ligação}} \Leftrightarrow p = \frac{\langle k \rangle}{n_{\text{nodos}} - 1}.$$




Fig. 1: Distribuição média de 100 simulações do grau do grafo de Erdos Renyi com $n_{\text{nodos}} = 100$ e $p_{\text{ligação}} = 40\%$

Substituindo no limite ficamos com:

$$\begin{aligned} \lim_{n \rightarrow \infty} \frac{(n-1)!}{(n-1-k)!k!} \frac{\langle k \rangle^k}{n-1} \left(1 - \frac{\langle k \rangle}{n-1}\right)^{n-1-k} &= \\ = \frac{\langle k \rangle^k}{k!} \lim_{n \rightarrow \infty} \frac{(n-1) \dots (n-k)(n-1-k) \dots (1)}{(n-1-k)!} &= \\ \times \frac{1}{(n-1)^k} \left(1 - \frac{\langle k \rangle}{n-1}\right)^{n-1} \left(1 - \frac{\langle k \rangle}{n-1}\right)^{-k} &= \\ = \frac{\langle k \rangle^k}{k!} \lim_{n \rightarrow \infty} \frac{(n-1) \dots (n-k)}{(n-1)^k} \left(1 - \frac{\langle k \rangle}{n-1}\right)^{n-1} \left(1 - \frac{\langle k \rangle}{n-1}\right)^{-k} &= \\ = \frac{\langle k \rangle^k}{k!} \lim_{n \rightarrow \infty} \frac{(n-1)}{(n-1)} \dots \frac{(n-k)}{(n-1)} \left(1 - \frac{\langle k \rangle}{n-1}\right)^{n-1} \left(1 - \frac{\langle k \rangle}{n-1}\right)^{-k} &= \end{aligned}$$

Temos que:

$$\begin{aligned} \lim_{n \rightarrow \infty} \frac{(n-1)}{(n-1)} \dots \frac{(n-k)}{(n-1)} &\rightarrow 1, \\ \lim_{n \rightarrow \infty} \left(1 - \frac{\langle k \rangle}{n-1}\right)^{n-1} &\rightarrow 1 \end{aligned}$$

e que

$$\lim_{n \rightarrow \infty} \left(1 - \frac{\langle k \rangle}{n-1}\right)^{-k} \rightarrow e^{-\langle k \rangle}$$

logo,

$$\lim_{n \rightarrow \infty} \frac{(n-1)}{(n-1)} \dots \frac{(n-k)}{(n-1)} \left(1 - \frac{\langle k \rangle}{n-1}\right)^{n-1} \left(1 - \frac{\langle k \rangle}{n-1}\right)^{-k} \rightarrow$$

$$\rightarrow e^{-\langle k \rangle}$$

Assim,

$$\lim_{n \rightarrow \infty} \binom{n-1}{k} p^k (1-p)^{n-1-k} \rightarrow \frac{\langle k \rangle^k}{k!} e^{-\langle k \rangle}$$

e concluímos que quando o número de nodos do grafo é muito grande podemos aproximar a distribuição do grau pela poisson com o parametro igual ao grau médio do grafo.




Fig. 2: Distribuição média de 100 simulações do grau do grafo de Erdos Renyi com $n = 10000$ e $p = 40\%$

Na figura 2 repetimos as simulações da figura 1, aumentando o número de nodos para 10000 e alterando a probabilidade de um nodo se ligar a outro de modo a manter o grau médio das simulações da figura 1, tendo em conta que a média da distribuição binomial é $(n-1)p$.

Confirmamos assim que quando n é muito grande a distribuição média do grau de um nodo do grafo de Erdos Renyi segue uma distribuição de poisson com parâmetro $\langle k \rangle$.

B. Coeficiente de agrupamento

Vamos falar agora do coeficiente de agrupamento do modelo ER. Para começar sabemos que o coeficiente de agrupamento de um nodo é dado por:

$$C_i = \frac{\text{numero de links entre os vizinhos de } i}{\text{total de links entre os vizinhos}}$$

Logo o coeficiente de agrupamento médio do grafo é dado por $C = \frac{\sum_{i=1}^n C_i}{n}$

Vamos supor que o grau de um nodo i é igual a k_i . Ou seja temos k_i nodos vizinhos de i . Assim, o número de links possíveis entre os vizinhos de i é dado por $\binom{k_i}{2} = \frac{k_i(k_i-1)}{2}$

Como os links são formados com probabilidade p , sabemos que o numero de links entre os vizinhos de i vai ser em média $\frac{k_i(k_i-1)}{2}p$

Logo,

$$C_i = \frac{\frac{k_i(k_i-1)}{2}p}{\frac{k_i(k_i-1)}{2}} = p = \frac{\langle k \rangle}{n-1}, \text{ logo } C = \frac{\sum_{i=1}^n p}{n} = \frac{np}{n} = C_i$$

Concluimos, então, que no modelo de Erdos Renyi o coeficiente de agrupamento diminui quando n aumenta, o que implica que quanto maior o número de nodos do grafo, menor o coeficiente de agrupamento. Na prática a maior parte dos grafos de Erdos Renyi vão ter um coeficiente de agrupamento muito baixo, o que não se verifica na grande maioria dos grafos reais.

C. Comprimento do percurso médio

Na secção anterior vimos que o coeficiente de agrupamento é muito pequeno se considerarmos n grande. Para calcularmos analiticamente o comprimento do percurso médio destes grafos vamos usar esse resultado. Consideremos n suficientemente grande tal que podemos aproximar o coeficiente de agrupamento a zero. Assim, o grafo vai ter uma estrutura de árvore. Se considerarmos que cada nodo tem em média grau $\langle k \rangle$ podemos dizer que cada nodo i

- à distância 1 tem $\langle k \rangle$ vizinhos; ...
- à distância m tem $\langle k \rangle^m$ vizinhos.

Assim se quisermos saber o número de vizinhos de um nodo até à distância j temos de somar todos os nodos vizinhos da distancia 1 ate à distancia j Logo o número de nodos até à distancia j , $N(j)$ é dado por:

$$\sum_{i=1}^j \langle k \rangle^i$$

Como se trata de uma serie geometrica temos que

$$N(j) = \frac{\langle k \rangle^{j+1} - 1}{\langle k \rangle - 1}$$

Sabemos que à distancia máxima o número de vizinhos do nodo i corresponde ao numero total de nodos n . Logo $N(d_{max}) = n$

Assim, temos que

$$n = \frac{\langle k \rangle^{d_{max}+1} - 1}{\langle k \rangle - 1}$$

$$n \approx \frac{\langle k \rangle^{d_{max}+1}}{\langle k \rangle} \approx \langle k \rangle^{d_{max}}$$

$$d_{max} \approx \frac{\log n}{\log \langle k \rangle}$$

Concluimos então que a distância máxima entre dois nodos é dado pela expressão acima e que o comprimento do percurso médio pode ser aproximado por esse valor.

Na figura 3 simulámos para vários n_{nodos} , 100 grafos de Erdos Renyi, alterando os valores de $p_{ligação}$ de modo a manter $\langle k \rangle = 39.6$ e calculando a média das distâncias médias entre os nodos cada grafo. Verificámos que o comprimento do percurso médio adopta $\langle d \rangle \approx \frac{\log n}{\log \langle k \rangle}$, o que é consistente




Fig. 3: Média das distâncias médias entre dois nodos em 100 grafos de Erdos Renyi, para $\langle k \rangle = 39.6$, consoante o número de nodos.

com os efeitos do mundo pequeno de grafos reais em que o comprimento do percurso médio aumenta de forma logarítmica e não linear.

II. GRAFO WATTS E STROGATZ

Neste modelo o grafo é construído da seguinte forma: os nodos são dispostos numa forma circular e cada nodo está ligado aos seus $2k$ vizinhos mais próximos, ie, o nodo está ligado aos k vizinhos mais próximos à esquerda e k vizinhos mais próximos à direita. Posteriormente temos um parametro p que corresponde à probabilidade de reordenar cada link que está ligado a cada nodo i e aos seus vizinhos da esquerda, sendo que cada link destes só pode ser reordenado uma vez e na reordenação tem obrigatoriamente de ficar ligado ao nodo i , podendo só mudar de vizinho. Depois da reordenação ficamos uma instância do grafo de Watts Strogatz[2], que apresenta algumas propriedades mais consistentes com grafos reais.

A. Distribuição do grau

Começamos por notar que quando $p = 0$, ou seja, quando o grafo mantém as suas condições iniciais, o grau de todos os nodos é igual a $2k$. Para $p > 0$ denotamos por $P_p(c)$ a probabilidade do grau de um nodo ser c dado que a probabilidade de reordenação dos link é p .

Como só os link que estão associados aos vizinhos da esquerda é que podem ser reordenados e a reordenação mantém o link associado ao nodo inicial, o número de links mínimo de cada nodo i é igual a k . Assim, podemos dizer que cada nodo i vai ter grau $c_i = k + n_i$ onde n_i corresponde à soma dos links onde i era vizinho à esquerda mas que não foram reordenados com probabilidade $1 - p$, n_i^1 , com os links que foram reordenados e passaram a estar associados a i com probabilidade $\frac{p}{n}$, n_i^2 pois a reordenação é aleatória entre todos os nodos.

Assim, a distribuição de n_i^1 vai ser uma binomial $(k, 1 - p)$ pois cada link à direita do nodo i não é reordenado com probabilidade $(1 - p)$ e são k links nestas condições, que vão ser ou não reordenados (pois o nodo i tem k vizinhos à direita). n_i^2 também vai ter uma distribuição binomial com parametros $(kn, p/n)$ pois existem kn links que podem ser reassociados ao nodo i (os k links de todos os nodos do grafo) com probabilidade $\frac{p}{n}$, para n grande esta distribuição pode ser aproximada a uma distribuição poisson com parâmetro $nk \times \frac{p}{n} = kp$.

Logo temos que,

$$P_p(n_i^1) = \binom{k}{n_i^1} (1 - p)^{n_i^1} p^{k - n_i^1}$$

e que

$$P_p(n_i^2) = \frac{(kp)^{n_i^2}}{n_i^2!} e^{-kp}$$

Como $n_i = n_i^1 + n_i^2$ e não sabemos exatamente a quantidade exata de cada um, $P_p(c)$ vai ser igual ao somatório das probabilidades de todas as possibilidades de n_i^1 e n_i^2

Logo temos que

$$P_p(c) = \sum_{n=0}^{\min(c-k, k)} \binom{k}{n} (1 - p)^n p^{k-n} \times \frac{(kp)^{c-k-n}}{(c-k-n)!} e^{-kp}$$

onde $n = n_i^1$ e $c - k - n = n_i^2$.




Fig. 4: Distribuições médias de 100 simulações do grau do grafo de Watts Strogatz com $n = 10000$ para vários p .

Na figura 4 confirmámos numericamente que para $p = 0\%$ a média das distribuições do grau médio é $2k$ e que à medida que p se aproxima de 100% a média das distribuições do grau médio se aproxima de uma binomial com média $2k - 1$. Para chegar a esta conclusão foram simulados 100 grafos de Watts Strogatz com 10000 nodos e várias probabilidades de um nodo se ligar a outro de modo a manter a média do grau constante.

B. Coeficiente de agrupamento

Como já vimos no modelo anterior o coeficiente de agrupamento de cada nodo i é dado por:

$$C_i = \frac{\text{numero de links entre os vizinhos de } i}{\text{total de links entre os vizinhos}}$$

Vamos tentar perceber qual é o coeficiente de agrupamento de um grafo onde $p = 0$.

Aqui, todos os nodos têm grau igual a $2k$, logo o número máximo de links possíveis entre os vizinhos é dado por $\binom{2k}{2} = \frac{2k(2k-1)}{2}$. Como $p = 0$, o número de links entre os vizinhos de cada nodo também é constante e é dado por $\frac{3k(k+1)}{2}$.

Assim, o coeficiente de agrupamento para $p = 0$, $C(0)$ é dado por:

$$C(0) = \frac{\frac{3k(k+1)}{2}}{\frac{2k(2k-1)}{2}} = \frac{3k(k+1)}{2k(2k-1)}$$

Sabemos que a probabilidade de um link ser reordenado é p , logo a probabilidade de dois vizinhos de um nodo i permanecerem conectados depois da reordenação é dado por $1 - p$. Esta é também a probabilidade de cada um desses vizinhos continuar conectado ao nodo i . Assim a probabilidade do triângulo formado inicialmente entre o nodo i e dois dos seus vizinhos permanecer depois da reordenação é $(1 - p)^3$. Logo, em média, o número de links entre os vizinhos do nodo i é igual ao numero inicial de links entre os vizinhos multiplicado por $(1 - p)^3$ ou seja $\frac{3k(k+1)}{2} \cdot (1 - p)^3$. Deste modo, podemos aproximar o coeficiente de agrupamento de um nodo, pela média do coeficiente de agrupamento obtendo que $C_i(p) = C(0) \times (1 - p)^3$.

Assim verificamos que quando $p < 1$ o agrupamento de um nodo no grafo de Watts Strogatz é superior ao de um nodo no grafo de Erdos Renyi, tal como acontece em grafos reais.[1] Também observamos nas simulações que apresentamos na figura 5 que é necessária muita aleatoriedade para destruir agrupamentos.

C. Comprimento do percurso médio

Nesta última secção vamos analisar o comprimento do percurso médio do grafo de Watts Strogatz quando $p = 0$. Para quando $p > 0$ a análise pode ser vista em [2]. Como o grafo é circular e os links não se alteraram, todos os nodos têm grau $2k$. Assim, o comprimento máximo entre dois nodos vai ser o comprimento entre os nodos que estão nos extremos de uma semi-circunferência do grafo. Se $k = 1$, os nodos estavam ligados apenas aos nodos do seu lado esquerdo e direito e portanto o caminho mais curto entre os extremos da semi-circunferência seria $\frac{n}{2}$. Assim, para qualquer k temos que o caminho mais curto entre os nodos mais distantes é $\frac{n}{2k}$. Como este grafo é um grafo simétrico e circular é fácil notar que o comprimento do percurso médio vai ser dado então por aproximadamente $\frac{n}{4k}$.

Calculámos a distância média entre dois nodos nas simulações que apresentamos na figura 5 e verificámos que pouca aleatoriedade consegue destruir a localidade dos grafos.




Fig. 5: Agrupamentos e comprimento do percurso médio relativos de 20 simulações do grau do grafo de Watts Strogatz com $n = 10000$ para vários p .

REFERENCES

- [1] Albert-László Barabási. *Network Science*. Cambridge University Press, 1 edition, 2016. Capítulo 3.
- [2] A. Barrat and M. Weigt. On the properties of small-world networks models. *The European Physical Journal B*, 13:547–560, 2000.
- [3] Sergey Dorogovtsev. *Lectures on Complex Networks*. Oxford University Press, 1 edition, April 2010. Capítulo 2.
- [4] Regina Duarte and Pedro Rio. Complex network science. https://github.com/pedrorio/complex_network_science, 2019.